UNIVERSITATEA TEHNICĂ DIN CLUJ-NAPOCA

Mag

Asistent virtual

Autor: Bodea George

Facultatea de Automatica
si Calculatoare

15 Ianuarie 2026

Cuprins

1 Introducere **2**
1.1 Definitie 2
1.2 Alexa 2

2 Design-ul proiectului **3**
2.1 ESP32-S2-DevKit-Lipo Olimex 3
2.2 INMP441 3
2.3 Protocolul I^2S 3
2.4 Silero VAD 4
2.5 Whisper 4
2.6 Descrierea proiectului 4

3 Analiza performanței **5**

4 Referințe **6**

1 Introducere

1.1 Definitie

Un asistent virtual (VA) este un agent software care poate îndeplini o gamă largă de sarcini sau servicii pentru un utilizator, pe baza inputului oferit de acesta, cum ar fi comenzi sau întrebări, inclusiv verbale. Astfel de tehnologii integrează adesea capabilități de tip **chatbot** pentru a eficientiza executarea sarcinilor.

În multe cazuri, utilizatorii pot adresa întrebări asistenților virtuali, pot controla dispozitivele de automatizare a locuinței și redarea conținutului media, precum și pot gestiona alte sarcini de bază, cum ar fi e-mailurile, și calendarele – toate prin **comenzi vocale**.

1.2 Alexa

Alexa este o tehnologie de **asistent virtual** comercializată de Amazon și implementată în aplicații software pentru smartphone-uri, tablete, difuzoare inteligente wireless și alte dispozitive electronice. Aceasta este capabilă de procesare a limbajului natural pentru sarcini precum interacțiunea vocală, redarea muzicii, setarea alarmelor, redarea de podcasturi, cărți audio, furnizarea de informații despre vreme, trafic, sport, alte informații în timp real și știri. Alexa poate, de asemenea, controla mai multe dispozitive inteligente, funcționând ca un sistem de automatizare a locuinței.

Figura 1: Dispozitiv Alexa

2 Design-ul proiectului

2.1 ESP32-S2-DevKit-Lipo Olimex

ESP32-S2-DevKit-Lipo este o placă de dezvoltare cu programator CH340, cu consum ultra-redus de energie, capabilă să funcționeze pe bază de baterie LiPo. Această placă este bazată pe modulul ESP32-S2-WROOM și dispune de 4 MB de memorie Flash.

Caracteristici:

- 320 KB SRAM
- 4MB Flash
- WiFi 1T1R 150Mbps
- Consum redus
- RGB LED

2.2 INMP441

INMP441 este un microfon MEMS omnidirecțional, de înaltă performanță, putere redusă, ieșire digitală, cu portul plasat in partea de jos. Soluția completă INMP441 constă dintr-un senzor MEMS, avand un convertor analog-digital, filtru anti-aliasing, un management al energiei și interfață standard I2S pe 24 de biți.

Caracteristici:

- Interfață digitală I2S cu date de înaltă precizie pe 24 de biți
- Raportul ridicat semnal/sunet este de 61 dBA
- Sensibilitate mare - 26 dBFS
- Răspuns în frecvență stabil de la 60 Hz la 15 kHz
- Consum redus de energie: consum redus de curent 1,4 mA

2.3 Protocolul I^2S

Inter-Integrated Circuit Sound (I^2S) este un protocol de interfață serială utilizat pentru transmiterea sunetului digital pe două canale, sub formă de modulație în cod de impulsuri (PCM), între componentele de tip circuit integrat (IC) ale unui dispozitiv electronic.

Un magistral I^2S separă semnalele de ceas (*clock*) de cele de date seriale, ceea ce duce la receptoare mai simple decât cele necesare în sistemele de comunicație asincrone, unde ceasul trebuie recuperat din fluxul de date.

Caracteristici:

- SCK: Ceas de date serial pentru interfața I2S
- WS: Selectarea cuvântului serial de date pentru interfața I2S
- L/R: Selectare canal stânga/dreapta
- SD: Ieșire de date seriala a interfeței I2S
- VCC: tensiune de intrare, 1,8 V până la 3,3 V
- GND: masa alimentarii

2.4 Silero VAD

Silero VAD este o rețea neuronală care detectează prezența vocii umane. Este utilizată în principal în aplicații IoT sau mobile.

Voice Activity Detection (VAD) reprezintă o clasă de algoritmi care etichetează fiecare cadru audio de scurtă durată ca fiind voce sau non-voce, pentru a controla procesarea ulterioară. În loc să trimită fiecare secundă a unui flux audio către sistemele de recunoaștere a vorbirii, sistemele inteligente folosesc VAD pentru a transmite doar segmentele care conțin cel mai probabil vorbire.

Caracteristici cheie:

- Acuratețe foarte bună
- Rapiditate ridicată
- Generalitate (funcționează în domenii și condiții de zgomot de fundal foarte diferite)
- Rată de eșantionare flexibilă
- Portabilitate

2.5 Whisper

Whisper este un sistem de recunoaștere automată a vorbirii (*Automatic Speech Recognition – ASR*), care permite transcrierea în mai multe limbi, precum și traducerea acestora în limba engleză. Modelele și codul de inferență sunt disponibile în regim *open-source*, oferind o bază solidă pentru dezvoltarea de aplicații utile și pentru cercetări ulterioare în domeniul procesării robuste a vorbirii.

2.6 Descrierea proiectului

Proiectul constă în realizarea unui asistent virtual similar cu Alexa. Din punct de vedere hardware, au fost utilizate următoarele componente: un microcontroler **ESP32-S2-DevKit-Lipo (Olimex)**, un microfon omnidirecțional **INMP441**, precum și un server pe care rulează modele de inteligență artificială, reprezentat de un laptop.

Conectarea dintre microfon și microcontroler a fost realizată prin intermediul **protocolului I^2S**, iar comunicarea dintre microcontroler și laptop s-a efectuat prin intermediul rețelei, folosind pachete de **4 KB de date per transmisie**.

Din punct de vedere software, este utilizat **Silero VAD**, care permite detectarea activității vocale și reconstruirea comenzii audio furnizate de utilizator pe server. După reconstruirea comenzii, aceasta este verificată pentru a determina dacă este adresată asistentului. Ulterior, folosind modelul **Whisper**, comanda audio este transformată în text.

Odată obținută comanda în format text, se poate apela **API-ul ChatGPT**, care, în funcție de conținutul comenzii, poate genera un răspuns text sau poate declanșa executarea unei funcții ce controlează un alt dispozitiv electronic.

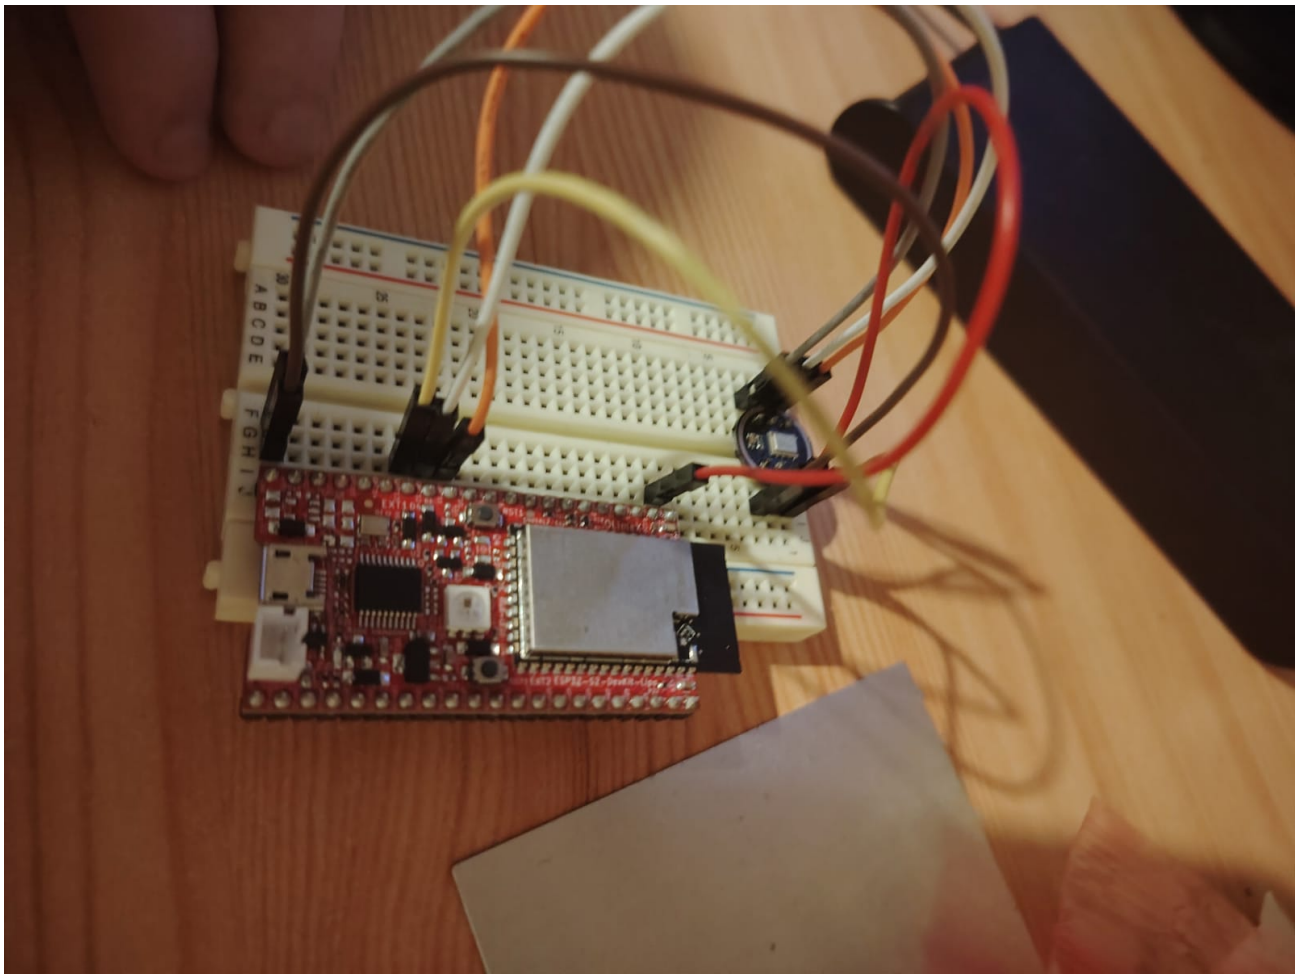

Figura 2: Componentele Hardware

3 Analiza performanței

Performanța sistemului este considerată rezonabilă, răspunsul asistentului virtual fiind generat la aproximativ 2-3 secunde după terminarea comenzii vocale. Această măsurătoare se bazează pe timpul mediu de procesare a comenzilor în condiții ideale.

O posibilă îmbunătățire ar fi efectuarea detectării vocale (*Voice Activity Detection*) direct pe microcontroller, fără a mai trimite datele audio către server. Din păcate, această soluție nu a putut fi implementată pe microcontroller-ul utilizat (**ESP32-S2-DevKit-Lipo**), din cauza memoriei RAM insuficiente.

Un alt aspect care poate fi optimizat este contextul din care pornește modelul AI, astfel încât interpretarea comenzilor să fie mai precisă și mai adaptată la mediul utilizatorului.

Dimensiunea pachetelor de date de 4 KB a fost aleasă astfel încât să permită sistemului VAD să recunoască cu acuratețe dacă există vorbire, fără a încetini transmiterea datelor către server.

4 Referințe

Referințe

[1] Wikipedia, Virtual Assistant, https://en.wikipedia.org/wiki/Virtual_assistant

[2] Wikipedia, Amazon Alexa, https://en.wikipedia.org/wiki/Amazon_Alexa

[3] CEPro, Amazon Unveils Alexa+ AI-Powered Smart Home Assistant, https://www.cepro.com/news/amazon-unveils-alexa-ai-powered-smart-home-assistant/147069/

[4] Olimex, ESP32-S2-DevKit-Lipo, https://www.olimex.com/Products/IoT/ESP32-S2/ESP32-S2-DevKit-Lipo/open-source-hardware

[5] ArduShop, Modul microfon omnidirectional I2S INMP441, https://ardushop.ro/ro/module/1944-modul-microfon-omnidirectional-i2s-inmp441-6427854029614.html

[6] Wikipedia, I^2S, https://en.wikipedia.org/wiki/I2S

[7] Github, silero-vad, https://github.com/snakers4/silero-vad

[8] Deepchecks, What is Whisper? Features & Getting Started, https://www.deepchecks.com/llm-tools/whisper/